

Devoir-projet : Applied Data Science

Filière: Génie Informatique

May 17, 2026

Ce mini-projet vous permettra de mettre en pratique vos compétences en data science, en traitement du langage naturel et en apprentissage automatique en utilisant des outils populaires tels que Python, Pandas, NLTK et Scikit-learn pour résoudre un problème réel de l'analyse des sentiments.

1 Description:

Dans ce projet, vous allez développer en trinôme (les binômes et monômes sont aussi acceptés) un modèle d'analyse de sentiment pour classer les commentaires du site web Hespress en fonction de leur tonalité : positif, négatif ou neutre. Vous utiliserez des bibliothèques telles que Pandas pour la manipulation des données, NLTK (Natural Language Toolkit) pour le traitement du langage naturel, et des techniques de machine learning pour entraîner un modèle à partir d'un jeu de données de commentaires annotés.

2 Objectifs :

- Collecte de données : Téléchargez ou scrapez un ensemble de données de commentaires du site et stockez-les dans un format compatible avec Pandas.
- Prétraitement des données : Utilisez Pandas pour nettoyer et préparer les données en supprimant les caractères spéciaux, les stopwords et en normalisant le texte.
- Exploration des données : Utilisez Pandas et des visualisations comme Matplotlib ou Seaborn pour effectuer une analyse exploratoire des données et comprendre la distribution des sentiments dans les commentaires, les mots les plus fréquents, etc.
- Entraînement du modèle : Utilisez NLTK pour tokeniser le texte et construire un vocabulaire, puis utilisez des techniques de machine learning avec des bibliothèques comme Scikit-learn pour entraîner un modèle d'analyse de sentiment, comme un classificateur Naïve Bayes.

- Évaluation du modèle : Utilisez des métriques telles que la précision, le rappel et le score F1 pour évaluer les performances de votre modèle sur un ensemble de données de test.
- Application du modèle : Déployez votre modèle entraîné pour prédire les sentiments des nouveaux commentaires de produits.

3 Rendu du devoir :

- La date limite pour soumettre le devoir est le 14 juin 2026 à 23h59.
- Le travail devra être rendu uniquement par l'un des membres du trinôme (au choix).
- Un notebook Jupyter ou un script Python détaillant les étapes suivies dans le projet, les choix de modélisation, les performances du modèle et les conclusions tirées.
- Le code source du projet, documenté et accompagné de commentaires expliquant chaque étape, ainsi que les dépendances nécessaires pour exécuter le code.